


ANÁLISIS DE MÉTODOS DE EXPRESIÓN DIFERENCIAL CON DATOS DE scRNA-seq

Maria Alejandra Rojo Orozco
Johan Hernando Largo Gonzalez
Jenny Lorena Patiño Rosas

Introducción



La tecnología de secuenciación de única célula a tomado relevancia al tener ventajas con respecto a la secuenciación de RNA-seq convencional (Svensson, V. et al., 2020).

- Mejor comprensión de la heterogeneidad del tejido (Cao, J. et al., 2020).
- Caracterizaciones de poblaciones de células raras (Jindal, A. et al., 2018; Nguyen, A. et al., 2018).
- Etiología de la enfermedad impulsada por el tipo celular (Schirmer, L. et al., 2019; Reyfman, P. A. et al., 2019)

Pregunta biológica

¿Cuál de los siguientes métodos estadísticos, *Wilcoxon*, *Prueba T*, *DESeq2* o *MAST*, es el más adecuado para detectar genes diferencialmente expresados (DEGs) en datos simulados de Single Cell Sequencing?



Objetivo

Comparar los métodos estadísticos *prueba de Wilcoxon*, *prueba t*, *DESeq2* y *MAST* en el análisis de expresión diferencial usando datos simulados de Single Cell Sequencing.

Objetivos Específicos

- Generar datos simulados de prueba con la biblioteca *splatter*.
 - Ejecutar los diferentes métodos de expresión diferencial con los datos generados.
 - Comparar los resultados obtenidos
 - Realizar recomendaciones para el análisis de expresión diferencial en datos de célula única.
- 

Diseño Experimental

1 Obtención y procesamiento de datos

2. Aplicar métodos de DE

3. Análisis de los resultados y métricas

4. Conclusiones

a) Simulación de datos con la librería splatter.

b) DEGs con DeFac Group por cluster

Ejecución de métodos estadísticos para el análisis de DEGs en datos de scRNA-seq simulados

Wilcoxon
Prueba T
DESeq2
MAST

A) Comparar numero de cell y DEGs.

B) Métricas
Precisión
Recall
F1 score
Accuracy
FDR



a) Simulación de datos



Datos de referencia :

```
> library("Seurat") #single cell pre-processing and processing PBMC Data
> library("SeuratData") #data reference PBMC
> pbmc3k
An object of class Seurat
13714 features across 2700 samples within 1 assay
Active assay: RNA (13714 features, 0 variable features)
2 layers present: counts, data
```

Tipo de células: Células mononucleares de sangre periférica (PBMC)

```
> tab1 <- round(table(data$seurat_annotatons)/sum(table(data$seurat_annotatons)),2)
> tab1
```

Naive	CD4 T Memory	CD4 T	CD14+ Mono	B	CD8 T	FCGR3A+ Mono
0.26	0.18	0.18	0.13	0.10	0.06	
NK	DC	Platelet				
0.06	0.01	0.01				



Simulación de datos Splatter

Mean:

- **RATE:** Tasa media de expresión génica.
- **SHAPE:** Forma de la distribución de la expresión génica.
- **LOCATION** y **SCALE:** Parámetros para la distribución del tamaño de las bibliotecas.
- **PROBABILITY:** Probabilidad de que un gen sea un valor atípico de expresión.

BCV:

- **COMMON DISP:** Dispersión común para la variabilidad de conteo.
- **DOF:** Grados de libertad para la variabilidad de conteo.

```
> params <- splatEstimate(data_counts) # parametros para la simulación
> params
A Params object of class SplatParams
Parameters can be (estimable) or [not estimable], 'Default' or 'NOT DEFAULT'
Secondary parameters are usually set during simulation

Global:
(GENES) (CELLS) [SEED]
13714 2700 548676

29 additional parameters

Batches:
[BATCHES] [BATCH CELLS] [Location] [Scale] [Remove]
1 2700 0.1 0.1 FALSE

Mean:
(RATE) (SHAPE)
13.6196558267908 0.58399566515946

Library size:
(LOCATION) (SCALE) (Norm)
7.67737406135792 0.43151683188261 FALSE

Exprs outliers:
(PROBABILITY) (LOCATION) (SCALE)
0.0250109377278693 4.76261054150334 1.03663845728074

Groups:
[Groups] [Group Probs]
1 1

Diff expr:
[Probability] [Down Prob] [Location] [Scale]
0.1 0.5 0.1 0.4

BCV:
(COMMON DISP) (DOF)
0.284346860844364 30.5292762680558

Dropout:
[Type] (MIDPOINT) (SHAPE)
none -0.148767957314464 -1.06380659330659

Paths:
[From] [Steps] [Skew] [Non-linear] [Sigma Factor]
0 100 0.5 0.1 0.8
```




```
sim.groups <- splatSimulate(  
  params,  
  group.prob = c(0.45, 0.23, 0.15, 0.10, 0.04, 0.03), # Probabilidades de pertenencia a cada grupo  
  de.prob = c(0.10, 0.09, 0.07, 0.06, 0.04, 0.04), # Probabilidades de expresión diferencial para cada grupo  
  de.facLoc = c(0.4, 1, 0.8, 0.8, 0.5, 1), # Localización del factor de expresión diferencial, ajustado para cada grupo  
  de.facScale = c(0.9, 0.9, 0.7, 0.8, 0.8, 0.9), # Escala del factor de expresión diferencial ajustada  
  batchCells = 4000, # Número de células por lote en la simulación (6000)  
  nGenes = 15000, # Incremento del número de genes  
  method = "groups", # Método de simulación (groups)  
  verbose = TRUE  
)
```

```
# Ajuste de los parámetros de simulación mejorada  
params_mejorada <- splatEstimate(data_counts)  
params_mejorada <- setParams(params_mejorada, dropout.type = "none", dropout.mid = -0.15, dropout.shape = -1.06)
```

```
> print(sim.groups)  
class: SingleCellExperiment  
dim: 15000 4000  
metadata(1): Params  
assays(6): BatchCellMeans BaseCellMeans ... TrueCounts  
counts  
rownames(15000): Gene1 Gene2 ... Gene14999 Gene15000  
rowData names(10): Gene BaseGeneMean ... DEFacGroup5  
DEFacGroup6  
colnames(4000): Cell1 Cell2 ... Cell3999 Cell4000  
colData names(4): Cell Batch Group ExpLibSize  
reducedDimNames(0):  
mainExpName: NULL  
altExpNames(0):
```

Diagrama de Violín por Cluster



1 Obtención y procesamiento de datos

```
##### Pre- procesamiento #####
```

```
matrix_counts <- sim.groups@assays@data@listData[["counts"]] # Not normalized
data_1 <- CreateSeuratObject(counts = matrix_counts)
data_1 <- NormalizeData(data_1, normalization.method = "LogNormalize", scale.factor = 10000)
data_1 <- FindVariableFeatures(data_1, selection.method = "vst", nfeatures = 2000)
data_1 <- ScaleData(data_1)
data_1_pca <- RunPCA(data_1, features = VariableFeatures(object = data_1))
ElbowPlot(data_1_pca)
data_1_SNN <- FindNeighbors(data_1_pca, dims = 1:18) # Ajustar el número de dimensiones
data_1_cl <- FindClusters(data_1_SNN, resolution = 0.9) # Ajustar la resolución
data_1_UMAP <- RunUMAP(data_1_cl, dims = 1:10)
data_1_cl <- AddMetaData(data_1_cl, metadata = Idents(object = data_1_cl), col.name = "Cluster")
DimPlot(data_1_UMAP, label = TRUE, reduction = "umap", pt.size = 0.5) + NoLegend()
```

```
table(Idents(data_1_cl)) #numro de celulas por cluster
table(colData(sim.groups)$Group) # Verificar la distribución de los grupos simulados
#
```

```
> table(Idents(data_1_cl)) #numro de celulas por cluster
```



```
  0    1    2    3    4    5
1838  891  573  397  157  144
```

```
> table(colData(sim.groups)$Group) # Verificar la distribución de los grupos simulados
```

```
Group1 Group2 Group3 Group4 Group5 Group6
 1834   894   578   396   158   140
```

```
> |
```

1 Obtención y procesamiento de datos



b) DeFacGroup

```
> head(de_factors,20)
DataFrame with 20 rows and 10 columns
```

	Gene	BaseGeneMean	OutlierFactor	GeneMean	DEFacGroup1	DEFacGroup2	DEFacGroup3	DEFacGroup4	DEFacGroup5	DEFacGroup6
	<character>	<numeric>	<numeric>	<numeric>	<numeric>	<numeric>	<numeric>	<numeric>	<numeric>	<numeric>
Gene1	Gene1	0.0313891	1	0.0313891	1	1	1	1.00000	1	1.00000
Gene2	Gene2	0.0514864	1	0.0514864	1	1	1	1.00000	1	1.00000
Gene3	Gene3	0.0182812	1	0.0182812	1	1	1	1.17241	1	1.00000
Gene4	Gene4	0.1162664	1	0.1162664	1	1	1	1.00000	1	1.00000
Gene5	Gene5	0.0560743	1	0.0560743	1	1	1	1.00000	1	2.74038
...	...	...	...	...	...	...	...	...	...	...
Gene16	Gene16	0.07990397	1	0.07990397	1.000000	1.00000	1	0.234134	1	1
Gene17	Gene17	0.00367092	1	0.00367092	1.000000	1.00000	1	1.000000	1	1
Gene18	Gene18	0.00615004	1	0.00615004	0.520741	1.00000	1	1.000000	1	1
Gene19	Gene19	0.00223743	1	0.00223743	1.000000	4.13984	1	0.780305	1	1
Gene20	Gene20	0.00247966	1	0.00247966	1.000000	1.00000	1	1.000000	1	1

DEGs esperados

Cluster	Num_DEGs_Overexpressed
Cluster_0 Cluster_0	577
Cluster_1 Cluster_1	552
Cluster_2 Cluster_2	388
Cluster_3 Cluster_3	351
Cluster_4 Cluster_4	190
Cluster_5 Cluster_5	246

Cálculo de DEGs

Cluster 1 vs Todos los demás
Cluster 2 vs Todos los demás
Cluster 3 vs Todos los demás
Cluster 4 vs Todos los demás
Cluster 5 vs Todos los demás
Cluster 6 vs Todos los demás

wilcoxon

DESeq2

MAST

T-test

p value < 0.05
Fold change 1.5



2. Aplicar métodos de DE

```
realizar_comparacion_todos <- function(data, test_use = "wilcox", only_pos = TRUE, min_pct = 0, logfc_threshold = 0) {  
  comparison_result <- FindAllMarkers(data,  
    only.pos = only_pos,  
    min.pct = min_pct,  
    logfc.threshold = logfc_threshold,  
    test.use = test_use)  
  
  comparison_result$p_val_adj <- p.adjust(comparison_result$p_val, method = "fdr")  
  return(comparison_result)  
}  
  
# Realizar comparación para DEFacGroup > 1.5 (solo sobreexpresados) usando diferentes métodos de prueba  
start_time <- Sys.time()  
comparison_result_wilcox <- realizar_comparacion_todos(data_1_cl, test_use = "wilcox", only_pos = TRUE, logfc_threshold = log2(1.5))  
comparison_result_t_test <- realizar_comparacion_todos(data_1_cl, test_use = "t", only_pos = TRUE, logfc_threshold = log2(1.5))  
comparison_result_deseq2 <- realizar_comparacion_todos(data_1_cl, test_use = "DESeq2", only_pos = TRUE, logfc_threshold = log2(1.5))  
comparison_result_mast <- realizar_comparacion_todos(data_1_cl, test_use = "MAST", only_pos = TRUE, logfc_threshold = log2(1.5))  
end_time <- Sys.time()
```

FindAllMarkers: Identifica genes diferencialmente expresados entre diferentes clústeres en datos de single-cell RNA-seq.

RESULTADOS

Número de DEGs por cada método

Cluster	DEGs esperados	Wilcoxon	T-Test	DESeq2	MAST
1	577	589	556	116	510
2	552	508	408	0	426
3	388	443	257	0	284
4	351	533	227	0	283
5	190	447	57	19	132
6	246	309	65	0	109
TOTAL	2304	2829	1570	135	1744

```
> print("Resumen de la cantidad de DEGs por clúster para cada método:")
```

```
[1] "Resumen de la cantidad de DEGs por clúster para cada método:"
```

```
> print(deg_summary_combined)
```

	Cluster	Wilcoxon_Num_DEGs	T_Test_Num_DEGs	DESeq2_Num_DEGs	MAST_Num_DEGs
1	0	802	487	72	582
2	1	550	418	0	454
3	2	54	67	114	496
4	3	422	260	68	289
5	4	486	216	59	262
6	5	249	61	23	104

```
> print("Resumen de DEFacGroup por clúster para cada método:")
```

```
[1] "Resumen de DEFacGroup por clúster para cada método:"
```

```
> print(head(summary_combined))
```

	Gene	cluster	Wilcoxon_DEFacGroup	T_Test_DEFacGroup	DESeq2_DEFacGroup	MAST_DEFacGroup
1	Gene13671	0	1.3119175	1.3119175	1.3119175	1.3119175
2	Gene9692	0	1.5077985	1.5077985	1.5077985	1.5077985
3	Gene12543	0	1.6214452	1.6214452	1.6214452	1.6214452
4	Gene5322	0	0.7609267	0.7609267	0.7609267	0.7609267
5	Gene4781	0	1.9741174	1.9741174	1.9741174	1.9741174
6	Gene5463	0	1.1093636	1.1093636	1.1093636	1.1093636

Métricas globales



$$\text{Precision} = \frac{\text{Verdaderos positivos}}{\text{Verdaderos positivos} + \text{Falsos positivos}}$$

$$\text{Recall} = \frac{\text{Verdaderos positivos}}{\text{Verdaderos positivos} + \text{Falsos negativos}}$$

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

$$\text{Accuracy} = \frac{\text{Verdaderos positivos} + \text{Verdaderos negativos}}{\text{Total de muestras}}$$

$$\text{FDR} = \frac{\text{Falsos positivos}}{\text{Falsos positivos} + \text{Verdaderos positivos}}$$


3. Análisis de los resultados y métricas

Métricas globales

Test	Precisión	Recall	F1 Score	Accuracy	FDR	AUROC	PRAUC
Wilcoxon	0.5206	0.6791	0.5894	0.8644	0.4793	0.8719	0.2919
T-Test	0.7592	0.5495	0.6376	0.9100	0.2407	0.8279	0.1279
DESeq2	0.8074	0.0502	0.0946	0.8609	0.1925	0.6825	0.1369
MAST	0.7391	0.5942	0.6588	0.9114	0.2608	0.8563	0.1356

```
> print(metrics_findallmarkers_df)
```

```
      Test precision  recall  f1_score  accuracy    fdr
Wilcoxon Wilcoxon 0.5001951 0.60815939 0.5489189 0.8606850 0.4998049
T-Test    T-Test 0.6872101 0.49193548 0.5734034 0.8978281 0.3127899
DESeq2    DESeq2 0.5059524 0.08064516 0.1391162 0.8605329 0.4940476
MAST      MAST 0.5294925 0.54933586 0.5392317 0.8697255 0.4705075
```



4. Conclusiones

- La clusterización es necesaria para la asignación precisa de DEGs, y tanto la resolución como el número de dimensiones influyen en la formación de grupos y, por ende, en la asignación de DEGs a cada grupo.
- La simulación es sensible a los parámetros manipulados, lo que puede afectar la reproducibilidad. Este aspecto debe considerarse especialmente en el contexto de herramientas como *splatSimulate*.
- El método *MAST* mostró el mejor desempeño en las métricas evaluadas. No obstante, la simulación puede mejorarse para permitir ajustes en las métricas.
- *DESeq2* aplica métodos de normalización y ajustes que funcionan bien para RNA-Seq en bulk, pero pueden ser demasiado estrictos para scRNA-seq, resultando en la eliminación de muchos verdaderos positivos (bajo recall).

Bibliografía

Cao, J., O'Day, D. R., Pliner, H. A., Kingsley, P. D., Deng, M., Daza, R. M., Zager, M. A., Aldinger, K. A., Blecher-Gonen, R., Zhang, F., Spielmann, M., Palis, J., Doherty, D., Steemers, F. J., Glass, I. A., Trapnell, C., & Shendure, J. (2020). A human cell atlas of fetal gene expression. *Science (New York, N.Y.)*, 370(6518), eaba7721. <https://doi.org/10.1126/science.aba7721>

Jindal, A., Gupta, P., Jayadeva, & Sengupta, D. (2018). Discovery of rare cells from voluminous single cell expression data. *Nature communications*, 9(1), 4719. <https://doi.org/10.1038/s41467-018-07234-6>

Nguyen, A., Khoo, W. H., Moran, I., Croucher, P. I., & Phan, T. G. (2018). Single Cell RNA Sequencing of Rare Immune Cell Populations. *Frontiers in immunology*, 9, 1553. <https://doi.org/10.3389/fimmu.2018.01553>

Reyfman, P. A., Walter, J. M., Joshi, N., Anekalla, K. R., McQuattie-Pimentel, A. C., Chiu, S., Fernandez, R., Akbarpour, M., Chen, C. I., Ren, Z., Verma, R., Abdala-Valencia, H., Nam, K., Chi, M., Han, S., Gonzalez-Gonzalez, F. J., Soberanes, S., Watanabe, S., Williams, K. J. N., Flozak, A. S., ... Misharin, A. V. (2019). Single-Cell Transcriptomic Analysis of Human Lung Provides Insights into the Pathobiology of Pulmonary Fibrosis. *American journal of respiratory and critical care medicine*, 199(12), 1517–1536. <https://doi.org/10.1164/rccm.201712-24100C>

Schirmer, L., Velmesshev, D., Holmqvist, S., Kaufmann, M., Werneburg, S., Jung, D., Vistnes, S., Stockley, J. H., Young, A., Steindel, M., Tung, B., Goyal, N., Bhaduri, A., Mayer, S., Engler, J. B., Bayraktar, O. A., Franklin, R. J. M., Haeussler, M., Reynolds, R., Schafer, D. P., ... Rowitch, D. H. (2019). Neuronal vulnerability and multilineage diversity in multiple sclerosis. *Nature*, 573(7772), 75–82. <https://doi.org/10.1038/s41586-019-1404-z>

Svensson, V., da Veiga Beltrame, E., & Pachter, L. (2020). A curated database reveals trends in single-cell transcriptomics. *Database : the journal of biological databases and curation*, 2020, baaa073. <https://doi.org/10.1093/database/baaa073>

